

EKF 参数估计. 零基础工程报告

ESE 650 HW2 Problem 1

Student ID: 18330723

2026 年 4 月 25 日

阅读说明: 本报告假设你~~没学过 Kalman 滤波~~、不知道什么叫非线性观测模型、只会 `numpy` 基础。我从一个隐藏变量 + 只能看到它的一些带噪声函数开始讲, 一路推到能把未知参数估出来。

目录

1 要解决的真实问题	2
1.1 本题的数学设定	2
1.2 为什么这题非平凡?	2
2 先搞清楚: 数据是什么	3
2.1 文件结构	3
2.2 数据是怎么生成的	3
2.3 $a = -1$ 的直观行为	3
3 先试: 能不能用线性 Kalman 滤波?	4
4 技巧一: 状态增广 (把参数变成状态)	5
4.1 问题: a 不在状态里, 怎么估它?	5
4.2 过程噪声的选择	5
5 技巧二: 一阶 Taylor 线性化 (EKF 核心)	6
5.1 EKF 基本思想	6
5.2 本题的 Jacobian	6
5.3 H 的第 2 列为 0 意味着什么?	6
6 完整 EKF 递推	7
6.1 代码	7
7 初始化: 一个决定成败的选择	8
7.1 $\mu_0 = [1, -1]$ 和 $\Sigma_0 = \text{diag}(2, 10)$	8
7.2 双模陷阱: 为什么 $\mu_{a,0}$ 的符号很重要	8
7.3 如果真的不知道 a 的符号?	8

目录	2
8 结果验证	9
8.1 本题数值结果	9
8.2 怎么判断 EKF 跑对了?	9
8.3 σ_a 为什么前快后慢?	9
9 常考陷阱	10
10 考题（按学习路径排序）	11

1 要解决的真实问题

场景：隐藏的摆动 + 未知的力

想象一个小球在弹簧上来回振荡，但弹簧的硬度系数 a 你不知道。你只能隔着一块磨砂玻璃观测它——玻璃模糊了小球的符号，你只能看到位置绝对值相关的带噪读数。

更糟：你看不到真实位置 x_k ，只能看到 y_k 。你想做两件事：

1. **联合估计** x_k （每一步真实位置）。
2. **同时估计** a （弹簧系数，未知但不变）。

1.1 本题的数学设定

系统方程

状态动力学：

$$x_{k+1} = a x_k + \epsilon_k, \quad \epsilon_k \sim \mathcal{N}(0, 1)$$

观测方程：

$$y_k = \sqrt{x_k^2 + 1} + \nu_k, \quad \nu_k \sim \mathcal{N}(0, \frac{1}{2})$$

已知： $T = 100$ 步观测 $\{y_k\}$ ， $x_0 \sim \mathcal{N}(1, 2)$ 。

真值： $a = -1$ （但我们假装不知道，要估出来）。

1.2 为什么这题非平凡？

三个难点

1. **状态不可见**：没有 x_k 的直接观测，只有 $y_k = \sqrt{x_k^2 + 1} + \nu$ 。从 y 反推 x 有歧义（ $+x$ 和 $-x$ 给同样的 y ）。
2. **观测非线性**： $h(x) = \sqrt{x^2 + 1}$ 不是线性函数，不能直接用 KF。
3. **参数 a 在动力学里**： a 不直接出现在观测里，要通过 x 的时间演化间接学到。

2 先搞清楚：数据是什么

2.1 文件结构

HW2 P1 数据

```
p1_data.npy    # 由 p1a.py 生成
|-- 'y':        (100,) 带噪观测
|-- 'T':        100, 步数
|-- 'a_true':   -1.0, 真值（验证用）
```

2.2 数据是怎么生成的

p1a.py（数据模拟）

```
np.random.seed(0)
T = 100
a_true = -1.0
x = np.random.normal(1, np.sqrt(2))      #  $x_0 \sim N(1, 2)$ 
y = np.zeros(T)
for k in range(T):
    nu = np.random.normal(0, np.sqrt(0.5))
    y[k] = np.sqrt(x**2 + 1) + nu          # 先观测
    eps = np.random.normal(0, 1)
    x = a_true * x + eps                  # 再递推状态
```

注意步骤顺序：每步先用当前 x_k 算 y_k ，再递推 x_{k+1} 。

2.3 $a = -1$ 的直观行为

- $x_{k+1} = -x_k + \epsilon$ 让 x 每步近似翻符号。
- 加 $\epsilon \sim \mathcal{N}(0, 1)$ 扰动。
- 结果： x 在 0 附近正负交替振荡。

反面： $a = +1$ 是随机游走； $|a| < 1$ 衰减到 0。

3 先试：能不能用线性 Kalman 滤波？

线性 KF 要求

系统必须线性 + 高斯： $x_{k+1} = Ax_k + w_k$, $y_k = Cx_k + v_k$ ，有漂亮闭式解。

本题情况：

- 动力学 $x_{k+1} = ax_k$ 在 (x, a) 联合状态下是双线性（含 ax 积）。
- 观测 $h(x) = \sqrt{x^2 + 1}$ 严重非线性。

结论：线性 KF 不行，需要扩展（Extended）版本。

4 技巧一：状态增广（把参数变成状态）

4.1 问题： a 不在状态里，怎么估它？

Joint State-Parameter Estimation

技巧：把未知参数当作不随时间变化的状态，塞进状态向量。

$$z_k = \begin{bmatrix} x_k \\ a \end{bmatrix} \in \mathbb{R}^2, \quad f(z_k) = \begin{bmatrix} a x_k \\ a \end{bmatrix}$$

第二行 $a_{k+1} = a_k$ 说明 a 不动。

4.2 过程噪声的选择

过程噪声协方差 Q

$$Q = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

- $Q_{11} = 1$: 对应 $\epsilon_k \sim \mathcal{N}(0, 1)$ 。
- $Q_{22} = 0$: a 完全不变，没有过程噪声。

后果： σ_a^2 只会单调下降，学到的越来越精确。

替代方案：若想跟踪慢变 a ，可设 $Q_{22} = 10^{-4}$ （ a 做随机游走）。本题 a 是常数，0 最自然。

5 技巧二：一阶 Taylor 线性化 (EKF 核心)

5.1 EKF 基本思想

在每个时刻的当前估计处做一阶 Taylor 展开，局部当成线性。

局部线性化

$$f(z) \approx f(\hat{z}) + F(z - \hat{z}), \quad h(z) \approx h(\hat{z}) + H(z - \hat{z})$$

其中 **Jacobian**: $F = \partial f / \partial z|_{\hat{z}}$, $H = \partial h / \partial z|_{\hat{z}}$ 。

5.2 本题的 Jacobian

F :

$$f(z) = \begin{bmatrix} ax \\ a \end{bmatrix} \Rightarrow F = \begin{bmatrix} a & x \\ 0 & 1 \end{bmatrix}$$

H :

$$h(z) = \sqrt{x^2 + 1} \Rightarrow H = \left[\frac{x}{\sqrt{x^2 + 1}}, 0 \right]$$

5.3 H 的第 2 列为 0 意味着什么？

信息流分析

$H[2] = 0 \Rightarrow$ 观测 y 不能直接更新 $\hat{a}$ 。 $\hat{a}$ 的更新通过**协方差耦合** Σ_{xa} 间接传递：

- 预测步 $F = \begin{bmatrix} a & x \\ 0 & 1 \end{bmatrix}$ 让 Σ_{xa} 变成非零。
- 更新步 y 修正 $\hat{x}$ 时，通过 $\Sigma_{xa} \neq 0$ 把信息灌到 $\hat{a}$ 。

必然推论：若 $x \approx 0$, $F_{12} = 0$, Σ_{xa} 不被撑开, a 不可辨识。

6 完整 EKF 递推

EKF 标准递推

预测步:

$$\hat{z}_{k|k-1} = f(\hat{z}_{k-1|k-1}), \quad \Sigma_{k|k-1} = F\Sigma_{k-1|k-1}F^\top + Q$$

更新步:

$$\begin{aligned} S_k &= H\Sigma_{k|k-1}H^\top + R \\ K_k &= \Sigma_{k|k-1}H^\top S_k^{-1} \\ \hat{z}_{k|k} &= \hat{z}_{k|k-1} + K_k(y_k - h(\hat{z}_{k|k-1})) \\ \Sigma_{k|k} &= (I - K_kH)\Sigma_{k|k-1} \end{aligned}$$

6.1 代码

EKF 主循环

```
mu = np.array([1.0, -1.0])          # x0 + a 初始猜 (关键!)
Sigma = np.array([[2.0, 0.0],
                  [0.0, 10.0]])      # x0 先验 + a 宽松先验
Q = np.array([[1.0, 0.0], [0.0, 0.0]])
R = 0.5

for k in range(T):
    x_est, a_est = mu
    # --- Prediction ---
    mu_pred = np.array([a_est * x_est, a_est])
    F = np.array([[a_est, x_est], [0.0, 1.0]])
    Sigma_pred = F @ Sigma @ F.T + Q
    # --- Update ---
    x_p = mu_pred[0]
    y_hat = np.sqrt(x_p**2 + 1)
    H = np.array([[x_p / np.sqrt(x_p**2 + 1), 0.0]])
    S = (H @ Sigma_pred @ H.T).item() + R
    K = (Sigma_pred @ H.T) / S
    mu = mu_pred + K.flatten() * (y[k] - y_hat)
    Sigma = (np.eye(2) - K @ H) @ Sigma_pred
```


7 初始化：一个决定成败的选择

7.1 $\mu_0 = [1, -1]$ 和 $\Sigma_0 = \text{diag}(2, 10)$

- $\mu_{x,0} = 1$: 题目给定 $x_0 \sim \mathcal{N}(1, 2)$ 的均值。
- $\Sigma_{xx,0} = 2$: 同上题目。
- $\mu_{a,0} = -1$: 关键先验。
- $\Sigma_{aa,0} = 10$: 对 a 承认“大致不知道”。

7.2 双模陷阱：为什么 $\mu_{a,0}$ 的符号很重要

h 偶函数 $\Rightarrow$ 后验双模

$h(x) = \sqrt{x^2 + 1}$ 满足 $h(x) = h(-x)$ ，所以轨迹 $\{x_k\}$ 和 $\{-x_k\}$ 给相同 $\{y_k\}$ 。
这导致 $p(a | y_{1:T})$ 有两个对称峰：

- $a = +1$: x 一直同号。
- $a = -1$: x 交替正负。

两者观测无区别！EKF 假设单高斯，只能跟一个峰。

$\mu_{a,0}$ 选错会怎样？

$\mu_{a,0} = +1 \Rightarrow$ EKF 被推到 +1 峰，收敛到错误的 $\hat{a} \approx +1$ 。

$\mu_{a,0} = -1 \Rightarrow$ 正确收敛到 $\hat{a} \approx -1$ 。

结果对错完全取决于初始化符号！这是 EKF + 多模后验的固有限制。

7.3 如果真的不知道 a 的符号？

需要**高斯混合滤波**（GSF）或**粒子滤波**：维护多个假设，看谁的边缘似然更高。

本题刻意用 EKF，就是为了暴露这个“只能跟单模”的经典问题。

8 结果验证

8.1 本题数值结果

指标	值
最终 $\hat{a}$	-1.0008
最终 σ_a	0.0104
真值 a	-1
误差	< 0.01 ($< 1\sigma$)

8.2 怎么判断 EKF 跑对了？

1. $\hat{a}$ 收敛到真值: $|\hat{a} - a_{\text{true}}|$ 在几个 σ_a 内。
2. σ_a 单调下降: 每次更新都在“学到”信息。
3. 曲线形状: σ_a 前期快、后期慢 (见下)。
4. 双模测试: 换 $\mu_{a,0} = +1$ 收敛到 $+1$ (错), 验证双模性质。

8.3 σ_a 为什么前快后慢？

观测 sensitivity

$$\left| \frac{\partial h}{\partial x} \right| = \frac{|x|}{\sqrt{x^2 + 1}}$$

- $|x|$ 大: sensitivity 接近 1, 观测信息丰富。
- $|x| \rightarrow 0$: sensitivity $\rightarrow 0$, 观测几乎无信息。

$a = -1$ 让 x 振荡 + 过程噪声拖 x 向 0 $\Rightarrow$ 后期 $|x|$ 小 $\Rightarrow$ 观测对 a 信息变少。

9 常考陷阱

Trap 1 . EKF 和 KF 的关系

EKF = KF 的非线性扩展，用 Jacobian F, H 代替 A, C 。精度只到一阶。
完全线性高斯时 EKF = KF（最优 MMSE）；非线性时是次优近似。

Trap 2 . 为什么 σ_a^2 只单调下降？

- $Q_{22} = 0 \Rightarrow$ 预测步不加不确定性。
- 更新步 $(I - KH)\Sigma$ 总收缩。

无正向来源，只会变小。

Trap 3 . 信息怎么流到 $\hat{a}$ ？

通过协方差耦合 Σ_{xa} ：

- 预测步 F 产生 off-diagonal。
- 更新步通过 $\Sigma_{xa} \neq 0$ 间接修正 $\hat{a}$ 。

Trap 4 . 把 h 换成 $h(x) = x^3$ 呢？

奇函数 $\Rightarrow$ 保留符号 $\Rightarrow a = \pm 1$ 观测分布不同 $\Rightarrow$ 后验单模 $\Rightarrow$ EKF 无论初值都收敛到真值。

Trap 5 . 改 R 的影响

- $R \rightarrow \infty$ ：不信观测 $\Rightarrow \hat{a}$ 停在初值。
- $R \rightarrow 0$ ：完全信观测 $\Rightarrow \hat{x}$ 精确但有双模歧义； $\hat{a}$ 快收敛但若错模会锁死错的。

Trap 6 . UKF 能解决双模问题吗？

不能。UKF 仍假设单高斯（只是用 sigma 点更精确传播前两阶矩）。要多模需要 GSF 或 PF。

10 考题（按学习路径排序）

数据与问题理解：

1. 题目给了什么？输出要什么？
2. 为什么线性 KF 用不了？
3. 什么是状态增广？本题怎么做的？
4. 为什么 $Q_{22} = 0$ 而不是 10^{-4} ？

EKF 机制：

5. 推导本题的 Jacobian F 和 H 。
6. 写出 EKF 完整递推（预测 + 更新）。
7. Kalman gain 在 $|x|$ 大和小时的行为？
8. 证明 σ_a^2 单调下降。

信息流与可辨识性：

9. H 的第 2 列为 0 意味着什么？信息怎么流到 $\hat{a}$ ？
10. 如果 $a \approx 0$ ， a 还能被辨识吗？
11. 为什么前期 σ_a^2 下降快、后期慢？

双模后验与失败模式：

12. 为什么 $h = \sqrt{x^2 + 1}$ 导致后验双模？
13. 初始化 $\mu_{a,0} = +1$ 会发生什么？
14. 如何解决双模问题？（GSF / PF）
15. 把 h 改成 x^3 会如何？

算法对比：

16. EKF 和 KF 的关系？完全线性时谁更优？
17. UKF 能解决本题的双模问题吗？
18. PF 能做本题吗？代价是什么？
19. R 极大或极小的行为？

“把参数当状态、线性化当桥梁、协方差传信息。
但记住：EKF 只能跟一个峰。”