

Policy Iteration · 零基础专题报告

ESE 650 HW3 Problem 1

Student ID: 18330723

2026 年 4 月 24 日

阅读说明：本报告假设你**完全没学过 MDP / 强化学习**。我会从一个直观场景出发，一步步建出所有概念。每个新名词都先问“为什么需要它”，再给定义。

目录

1 从一个真实问题开始	2
2 把问题写成数学：MDP 五元组	3
2.1 本题的 MDP 具体长啥样	3
3 什么叫“好”的策略？	4
3.1 策略是什么	4
3.2 衡量策略好坏：两个问题和 γ 的救场	4
3.3 价值函数：对策略打分	4
4 Bellman 方程：一个惊人的递归	5
4.1 直觉	5
4.2 Bellman 评估方程（固定 π ）	5
4.3 Bellman 最优性方程（ π 未知）	5
5 步骤 1：策略评估（给定 π ，算 J^π ）	6
5.1 把 Bellman 方程写成矩阵	6
5.2 $(I - \gamma T^\pi)$ 为什么可逆？	6
5.3 直观理解：为什么这个逆矩阵是“累积奖励”	6
5.4 本题实现	6
6 步骤 2：策略改进（给定 J^π ，找更好的 π' ）	7
6.1 Q 函数：“如果这一步偏离 π 会怎样？”	7
6.2 贪婪改进	7
6.3 Policy Improvement 定理（惊人结果）	7
6.4 直观理解	7

目录	2
7 合起来：Policy Iteration 算法	8
7.1 为什么一定会停？（收敛性）	8
7.2 本题实际运行	8
8 对比：Value Iteration（另一条路）	9
9 验证结果	10
9.1 要看哪些指标	10
9.2 初始策略“一直往东”的值函数长什么样	10
10 口试常考陷阱（速查）	11
11 考题：按学习路径排序	12

1 从一个真实问题开始

场景：会滑倒的机器人

想象一个 10×10 的网格房间。一个机器人站在位置 $(1, 1)$ ，它想走到位置 $(8, 1)$ 充电。
问题是：

- 这个机器人不完美。你让它往东走，70% 概率真的往东，10% 概率往北，10% 概率往南，10% 概率原地打滑不动。
- 房间里有些格子是墙（边界 + $(3, 2)$ 处有个障碍）。撞墙的话机器人卡住，每步扣 10 分。
- 每走一步会扣 1 分。
- 到达目标 $(8, 1)$ 就停下，不再扣分。

你要做的：给机器人编一个“**决策手册**”——在每个格子上，应该往哪个方向走？
这个决策手册就叫**策略 (policy)**，记作 π 。

为什么这不是个简单的问题？

如果机器人是**确定的**（你让它往东它就往东），这就是经典的最短路径问题，用 BFS 几行就解决了。

但这里机器人**随机**打滑。你让它往东，它可能往北。所以：

- “直线朝目标冲”的策略可能不是最优的——它可能会因为打滑撞墙，扣很多分。
- “最优决策手册”必须考虑每个格子周围的随机性。

这就需要一个能处理**随机 + 序贯决策**的数学框架：**马尔可夫决策过程 (MDP)**。

2 把问题写成数学：MDP 五元组

马尔可夫决策过程（MDP）

一个 MDP 由 5 样东西组成： $\mathcal{M} = (\mathcal{X}, \mathcal{U}, T, r, \gamma)$.

- $\mathcal{X}$: **状态集合**。本题 = 100 个格子.
- $\mathcal{U}$: **动作集合**。本题 = {N,S,E,W}, 4 个.
- $T(x, u, x') = P(x' | x, u)$: **转移概率**。在状态 x 做动作 u 之后，跳到 x' 的概率.
- $r(x, u, x')$: **奖励函数**。给出做完这一步后的即时得分.
- $\gamma \in [0, 1)$: **折扣因子**。用来“淡化”远期奖励（见 §3.2）.

马尔可夫性：下一状态只依赖当前状态和动作，不依赖更早历史。这是 MDP 之所以“Markov”的来源.

2.1 本题的 MDP 具体长啥样

状态: (x, y) , $x, y \in \{0, \dots, 9\}$. (0,0) 在左下角。共 $10 \times 10 = 100$ 个状态.

动作: 4 个方向, $\{N, S, E, W\}$. 每个状态（除了目标和障碍）都可选.

转移概率: 假如你选了“往东（E）”，结果是

$$\begin{cases} \text{真的向东} & P = 0.7 \\ \text{向北（E 左侧）} & P = 0.1 \\ \text{向南（E 右侧）} & P = 0.1 \\ \text{原地不动} & P = 0.1 \end{cases}$$

如果“真的向东”会走出边界或进障碍，机器人就原地不动（撞墙）.

奖励:

$$r = \begin{cases} 0 & \text{到达目标 (8,1) (吸收, 之后一直是 0)} \\ -10 & \text{身处障碍格 (sticky: 进去就出不来)} \\ -1 & \text{其他格子 (每步扣 1 分)} \end{cases}$$

折扣: $\gamma = 0.9$.

容易忽略的细节：吸收（absorbing）状态

“目标”和“障碍”都是**吸收状态**——一旦进去，机器人就被困住，无法再出来。

- 目标 (8,1): 吸收 + 之后每步奖励 0 $\rightarrow$ 最终价值 = 0.
- 障碍: 吸收 + 之后每步奖励 -10 $\rightarrow$ 最终价值 = $-10 - 10\gamma - 10\gamma^2 - \dots = \frac{-10}{1-\gamma} = -100$.

这也是为什么障碍格的价值会深到 -100 左右.

3 什么叫“好”的策略？

3.1 策略是什么

策略 (Policy)

一个**确定性策略** $\pi: \mathcal{X} \rightarrow \mathcal{U}$ 就是一本手册：给我一个状态 x ，我告诉你在这里该做什么动作 $\pi(x)$ 。

例子：“一直往东”策略 $\pi_0(x) \equiv E$ 对所有 x 。

策略是本题真正的解。我们要找的就是**最优策略** π^* 。

3.2 衡量策略好坏：两个问题和 γ 的救场

现在想给一个策略 π 打分。直觉：从状态 x 出发，按 π 走下去，总得分有多少？

但有两个问题：

1. 时间是无穷的：若机器人永远走不到目标，总分岂不是 $-\infty$ ？
2. 环境是随机的：每次跑一遍得分都不一样，到底该用哪次？

解决问题 2：对**期望**求和 $\mathbb{E}[\dots]$ 。

解决问题 1：用**折扣因子** $\gamma < 1$ ，把第 k 步的奖励乘 γ^k ：

$$\underbrace{r_0}_{\text{现在}} + \underbrace{\gamma r_1}_{\text{明天}} + \underbrace{\gamma^2 r_2}_{\text{后天}} + \dots$$

为什么这样就不会无穷？因为即使每步奖励 $\leq M$ ，总和也有界：

$$\sum_{k=0}^{\infty} \gamma^k M = \frac{M}{1-\gamma} < \infty$$

γ 的另一个解释：机器人对未来的“耐心”。 $\gamma = 0$ 完全短视； $\gamma \rightarrow 1$ 极度长远；本题 $\gamma = 0.9$ 相当于看大约 $1/(1-\gamma) = 10$ 步远。

3.3 价值函数：对策略打分

策略 π 的价值函数 J^π

$$J^\pi(x) = \mathbb{E} \left[\underbrace{r_0 + \gamma r_1 + \gamma^2 r_2 + \dots}_{\text{按 } \pi \text{ 走下去的总折扣奖励}} \mid x_0 = x \right]$$

这是一个函数 $J^\pi: \mathcal{X} \rightarrow \mathbb{R}$ ，告诉你从每个状态出发按 π 走能期望得多少分。

最优价值函数： $J^*(x) = \max_{\pi} J^\pi(x)$ ，达到它的策略就是**最优策略** π^* 。

4 Bellman 方程：一个惊人的递归

4.1 直觉

一句话直觉

“从 x 开始的总价值 = 当前这一步奖励 + 折扣 $\times$ 下一状态的总价值”

为什么这样？因为**马尔可夫性**：未来只依赖当前状态，不依赖到达它的路径。所以“明天以后”的价值和“从明天开始”的价值一样。

4.2 Bellman 评估方程（固定 π ）

Bellman 评估方程

对任意策略 π ：

$$J^\pi(x) = \mathbb{E}_{x'} \left[r(x, \pi(x), x') + \gamma J^\pi(x') \right]$$

展开期望：

$$J^\pi(x) = \sum_{x'} T(x, \pi(x), x') \left[r(x, \pi(x), x') + \gamma J^\pi(x') \right]$$

推导（严格版）：

$$\begin{aligned} J^\pi(x) &= \mathbb{E}[r_0 + \gamma r_1 + \gamma^2 r_2 + \cdots \mid x_0 = x] \\ &= \mathbb{E}[r_0 \mid x_0 = x] + \gamma \mathbb{E}[r_1 + \gamma r_2 + \cdots \mid x_0 = x] \\ &= \mathbb{E}_{x'}[r(x, \pi(x), x')] + \gamma \mathbb{E}_{x'}[\mathbb{E}[r_1 + \gamma r_2 + \cdots \mid x_1 = x']] \\ &= \mathbb{E}_{x'}[r(x, \pi(x), x')] + \gamma \mathbb{E}_{x'}[J^\pi(x')] \\ &= \mathbb{E}_{x'}[r(x, \pi(x), x') + \gamma J^\pi(x')] \end{aligned}$$

4.3 Bellman 最优性方程（ π 未知）

Bellman 最优性方程

对最优价值 J^* ：

$$J^*(x) = \max_{u \in \mathcal{U}} \mathbb{E}_{x'} \left[r(x, u, x') + \gamma J^*(x') \right]$$

和评估方程的唯一区别：多了个 $\max_u$ 。

直觉：最优策略在每个状态选让期望总回报最大的动作，这个动作的期望回报就是 $J^*(x)$ 。

评估 vs 最优性的关键差异

- 评估方程**线性**（固定 π ，没有 $\max$ ） $\rightarrow$ 可以直接解 100 元一次方程组。
- 最优性方程**非线性**（ $\max$ 是非线性操作） $\rightarrow$ 不能直接解。

Policy Iteration 的聪明之处在于：**不直接碰最优性方程，而是反复用评估方程。**

5 步骤 1: 策略评估 (给定 π , 算 J^π)

5.1 把 Bellman 方程写成矩阵

假设 100 个状态编号 $0, 1, \dots, 99$ 。把 J^π 和 R^π 写成 100 维向量, T^π 是 100×100 的随机矩阵:

$$J^\pi = R^\pi + \gamma T^\pi J^\pi$$

移项: $(I - \gamma T^\pi)J^\pi = R^\pi$, 得到

$$J^\pi = (I - \gamma T^\pi)^{-1} R^\pi$$

100 × 100 的矩阵求逆就是几毫秒的事。这就是为什么本题用线性求解而不是迭代: 精确 + 快。

5.2 $(I - \gamma T^\pi)$ 为什么可逆?

可逆性证明

事实 1: T^π 是随机矩阵 (每行和为 1) $\rightarrow$ 谱半径 $\rho(T^\pi) \leq 1$.

事实 2: $\gamma < 1 \rightarrow \rho(\gamma T^\pi) = \gamma \rho(T^\pi) < 1$.

推论: $(I - \gamma T^\pi)^{-1} = \sum_{k=0}^{\infty} (\gamma T^\pi)^k$ 是收敛的 Neumann 级数 $\rightarrow$ 矩阵可逆。

5.3 直观理解: 为什么这个逆矩阵是“累积奖励”

展开 Neumann 级数:

$$(I - \gamma T^\pi)^{-1} R^\pi = R^\pi + \gamma T^\pi R^\pi + \gamma^2 (T^\pi)^2 R^\pi + \dots$$

第 k 项的含义: “从现在开始, k 步之后的期望奖励, 折扣 γ^k ”。加起来 = 总折扣奖励。这与 J^π 的定义完全一致。

5.4 本题实现

```
def policy_evaluation_linear(policy):
    T_pi = np.zeros((N_STATES, N_STATES))
    R_pi = np.zeros(N_STATES)
    for s in range(N_STATES):
        a = policy[s]
        T_pi[s, :] = T[s, a, :]
        R_pi[s] = R[s, a]
    V = np.linalg.solve(np.eye(N_STATES) - GAMMA * T_pi, R_pi)
    return V
```

6 步骤 2: 策略改进 (给定 J^π , 找更好的 π')

6.1 Q 函数: “如果这一步偏离 π 会怎样?”

动作价值函数 Q^π

$$Q^\pi(x, u) := \mathbb{E}_{x'}[r(x, u, x') + \gamma J^\pi(x')]$$

含义: 在状态 x 强行做动作 u (哪怕 $u \neq \pi(x)$), 然后之后再按 π 走, 总期望奖励.

注意 $Q^\pi(x, \pi(x)) = J^\pi(x)$ —— 按 π 做跟直接按 π 走一样.

6.2 贪婪改进

策略改进规则

新的策略: 在每个状态选当前 Q^π 最大的动作.

$$\pi'(x) = \arg \max_{u \in \mathcal{U}} Q^\pi(x, u)$$

6.3 Policy Improvement 定理 (惊人结果)

定理: π' 一定不差于 π

用上面规则得到的 π' 满足: 对每一个状态 x , 都有 $J^{\pi'}(x) \geq J^\pi(x)$.

更强: 等号处处成立 $\iff \pi$ 已经是最优策略.

证明 sketch (不怕被问就记这个):

第 1 步: 由 π' 的定义, 对每个 x :

$$J^\pi(x) = Q^\pi(x, \pi(x)) \leq \max_u Q^\pi(x, u) = Q^\pi(x, \pi'(x))$$

第 2 步: 展开最右边:

$$Q^\pi(x, \pi'(x)) = \mathbb{E}_{x'}[r(x, \pi'(x), x') + \gamma J^\pi(x')]$$

第 3 步: 把 $J^\pi(x')$ 再用一次不等式换成 $Q^\pi(x', \pi'(x'))$, 无穷嵌套下去:

$$J^\pi(x) \leq \mathbb{E}[r_0 + \gamma r_1 + \gamma^2 r_2 + \dots \mid x_0 = x, \text{按 } \pi' \text{ 走}] = J^{\pi'}(x)$$

证毕。

6.4 直觉理解

如果你在每个状态都把自己“能看到的一步”做到最优, 长期下来不会比原来差。这个看似显然的结论其实需要上面的递归论证——因为要证明“不只是下一步变好, 整条路都变好”。

7 合起来: Policy Iteration 算法

Policy Iteration 算法

1. 任选初始策略 π_0 (本题: “一直往东”).
2. 循环 ($k = 0, 1, 2, \dots$):
 - (a) **策略评估**: $J^{\pi_k} \leftarrow (I - \gamma T^{\pi_k})^{-1} R^{\pi_k}$.
 - (b) **策略改进**: $\pi_{k+1}(x) \leftarrow \arg \max_u Q^{\pi_k}(x, u)$.
 - (c) 若 $\pi_{k+1} = \pi_k$ 就停止.

7.1 为什么一定会停? (收敛性)

有限步收敛

1. 确定性策略的总数 $= |\mathcal{U}|^{|\mathcal{X}|} = 4^{100}$, 有限.
2. 每一轮要么 $\pi_{k+1} = \pi_k$ (已最优, 停止), 要么严格改进某些状态的价值 (由 PI 定理).
3. 价值单调递增 + 有上界 (J^*) + 策略有限 $\Rightarrow$ 有限步内必定收敛.

实际上远比 4^{100} 少得多——本题 4 步基本搞定.

7.2 本题实际运行

起点: $\pi_0 =$ “一直往东”, $J^{\pi_0}(1, 1) = -7.54$.

每轮 **policy changes** (和上一轮相比改动的格子数):

$$84 \rightarrow 31 \rightarrow 18 \rightarrow 6$$

起点价值变化: $-7.54 \rightarrow \dots \rightarrow -6.74$ (越接近 0 越好, 最好是 0).

最终策略: 从 (1,1) 出发, 箭头指向 (8,1), 绕开障碍 (3,2).

8 对比：Value Iteration（另一条路）

Value Iteration

直接用 Bellman 最优性方程做迭代更新：

$$J_{k+1}(x) = \max_u \mathbb{E}_{x'}[r(x, u, x') + \gamma J_k(x')]$$

不显式维护策略，迭代到 J 收敛后再提取 π^* 。

收敛性： Bellman operator 是 γ -压缩映射 $\rightarrow$ 线性收敛 $\|J_k - J^*\|_\infty \leq \gamma^k \|J_0 - J^*\|_\infty$ 。需要很多轮（ $\gamma = 0.9$ 要 100+ 轮才让误差降到 10^{-5} ）。

	Policy Iteration	Value Iteration
每轮代价	$O(n^3)$ （线性求解）	$O(n^2 \mathcal{U})$ （Bellman backup）
轮数	少（本题 4）	多（可能几百）
评估精度	精确	逼近
何时用	小 n 、想要精确值	大 n 、只要 π^*

结论： 本题 $n = 100$ 不大，PI 每轮花几毫秒，4 轮收敛 $\rightarrow$ 选 PI。

9 验证结果

9.1 要看哪些指标

1. **Policy changes 递减到 0**: $84 \rightarrow 31 \rightarrow 18 \rightarrow 6 \rightarrow \dots \rightarrow 0$, 这是收敛的铁证.
2. **起点价值 $J(1,1)$ 单调上升**: $-7.54 \rightarrow \dots \rightarrow -6.74$.
3. **值函数热图合理**:
 - 目标附近颜色亮 (值接近 0) .
 - 离目标远的格子暗 (值更负) .
 - 障碍格最暗 (值 ≈ -100) .
4. **策略箭头几何合理**: 从起点到目标的路径明显绕开障碍 (3,2); 远处的格子箭头基本指向目标方向.

9.2 初始策略“一直往东”的值函数长什么样

- 第 1 行 (目标所在行): 从 $(1,1) = -7.54$ 单调增加到 $(8,1) = 0$, 这一行能工作.
- 第 2 行以上: 每个格子的值都 ≈ -10 .

为什么上面几行全是 -10 ? 因为“一直往东”无法让 y 下降。在第 2 行及以上, 机器人永远走不到目标, 每步 -1 , 无穷长期累积:

$$-1 \cdot \frac{1}{1-\gamma} = \frac{-1}{0.1} = -10$$

这个数字恰好告诉你: **初始策略在大多数状态上是无用的**, 所以 PI 有很大改进空间.

10 口试常考陷阱（速查）

Trap 1 · 评估方程 vs 最优性方程记混

评估（线性）： $J^\pi = R^\pi + \gamma T^\pi J^\pi$ ，无 $\max$ 。

最优性（非线性）： $J^*(x) = \max_u[\dots]$ 。

记忆：给定 π 就没有 $\max$ ；要找最优就有 $\max$ 。

Trap 2 · 目标 $\text{reward} = 0$ 和 $\text{reward} = +10$ 哪个对？

等价。课本经常写“到目标奖励 +10”；本题实现是“进入目标后每步奖励 0 + 吸收”。两者只差一个常数（前者把所有 reward 整体平移），不影响最优策略 π^* ，只改变 J^* 的绝对值。

Trap 3 · $\gamma = 1$ 行不行？

只有当有 **proper policy**（能在有限期望时间内达到终止状态）才行。否则 J^π 可能无界。本题因为有吸收状态，是 proper 的， $\gamma = 1$ 理论可行；但数值上 $(I - T^\pi)$ 条件数差，会不稳定，所以加 $\gamma = 0.9$ 保险。

Trap 4 · Q 函数和 J 函数的关系

$$Q^\pi(x, u) = \mathbb{E}[r + \gamma J^\pi(x')], \quad J^\pi(x) = Q^\pi(x, \pi(x))$$

Q 是“如果偏离 π 做 u 一下再回归 π ”的价值； J 是“一直接 π ”的价值。两者差在“这一步”的动作自由度。

Trap 5 · 障碍是 sticky 的含义

“sticky”就是吸收状态——一旦踏进去，下一步无论做什么动作都留在原地（每步扣 10 分）。所以障碍的价值 $= -10/(1 - \gamma) = -100$ 。不是“立刻 -10 然后消失”，而是“永远 -10”。

Trap 6 · Reward vs Cost 的符号

本题用 **reward**（大越好），所以代码用 **argmax**。

很多教材（包括 Bertsekas 的 DP 教材）用 **cost**（小越好），最优性写成 $J^*(x) = \min_u[\dots]$ ，策略改进用 **argmin**。

两者只差一个负号，不要记混。本题 report 的 LaTeX 写“最大化”没问题。

11 考题：按学习路径排序

基础理解（必会）：

1. 什么是 MDP？给出本题的 5 元组.
2. “策略”和“价值函数”分别是什么？
3. 为什么需要 γ ？ $\gamma = 0$ 和 $\gamma \rightarrow 1$ 的物理含义？
4. 吸收状态是什么？为什么障碍格的值 ≈ -100 ？

方程与推导（中等）：

5. 写出 Bellman 评估方程并推导.
6. 写出 Bellman 最优性方程。和评估方程的区别在哪？
7. 证明 $(I - \gamma T^\pi)$ 可逆.
8. Neumann 级数 $\sum (\gamma T^\pi)^k R^\pi$ 每一项的物理意义是什么？

算法细节（高阶）：

9. 证明 Policy Improvement 定理： $J^{\pi'} \geq J^\pi$ 逐分量.
10. 为什么 PI 有限步收敛？至多多少步？
11. PI 和 VI 的 trade-off 是什么？本题为什么选 PI？
12. 如果把 γ 改为 0.5，行为会如何变化？
13. 若初始策略是“一直往西”（远离目标），PI 依然收敛吗？

失败模式与陷阱（加分题）：

14. 本题为什么“一直往东”在上面几行值都是 -10 ？
15. 如果转移改成确定性 ($0.7 \rightarrow 1.0$)，PI 步数会如何变？
16. 如果奖励函数给每个状态都加一个常数 c ，最优策略会变吗？（答：不变）
17. Policy Iteration 适用吗？一连续状态/动作、部分观测.
18. 说出至少一个你觉得本题实现可以改进的地方.

“评估是线性，改进是贪婪；二者交替必收敛。”