

HW2 & HW3 口试复习（工程叙事版）

ESE 650: Learning in Robotics

Student ID: 18330723

2026 年 4 月 24 日

本文档的阅读方法：

每一题按**工程叙事流程**展开：

原始数据 → 物理意义 → 数学表示 → 状态设计 → 算法维护 → 验证指标

每个环节后给 3 ~ 5 题**黄色 Q&A 卡片**，教授大概率会按这个顺序问。

答题原则：被问时先回到该环节的大图，把这一步的“为什么要这样”讲清楚，再给公式或代码细节。

目录

1 HW2 P1 · EKF 参数估计	2
1.1 考题（按叙事顺序）	3
2 HW2 P2 · 四元数 UKF 姿态估计	4
2.1 考题（按叙事顺序）	6
3 HW3 P1 · Policy Iteration	8
3.1 考题（按叙事顺序）	9
4 HW3 P2 · Particle Filter SLAM (KITTI)	10
4.1 考题（按叙事顺序）	11
5 HW3 P3 · TinyNeRF	13
5.1 考题（按叙事顺序）	14
6 跨章叙事 · 5 题的共同骨架	16

1 HW2 P1 • EKF 参数估计

1. 给了什么数据？

一个模拟器给了你 $T = 100$ 步的观测 $\{y_k\}$ （未给 x_k ！只有观测），系统方程是

$$x_{k+1} = a x_k + \epsilon_k, \quad \epsilon \sim \mathcal{N}(0, 1)$$

$$y_k = \sqrt{x_k^2 + 1} + \nu_k, \quad \nu \sim \mathcal{N}(0, \frac{1}{2})$$

未知的是 **参数 a （真值 = -1）**， $x_0 \sim \mathcal{N}(1, 2)$ 。

任务：只给 $\{y_k\}$ ，估出 a 。

2. 这些数据物理意义？为什么能 identify a ？

观测 y_k 包含 x_k 的幅度信息（但不含符号）； x_k 的动力学由 a 主导。多步观测组合起来就能推出 a ——若 $a = -1$ ， x 序列交替正负，整体在 0 附近振荡；若 $a = +0.5$ ， x 迅速衰减到 0 附近。这些**时间模式的差异**让 y 间接暴露 a 。

陷阱： $h(x) = \sqrt{x^2 + 1}$ 是**偶函数**，所以 $a = +1$ （ x 始终同号）和 $a = -1$ （ x 交替符号）会给出完全相同的 $\{y_k\}$ 分布 → **后验天然双模**。

3. 状态怎么设计？

原本只有状态 x ；但 a 也要估。常用技巧：**参数增广**，把 a 当作一个“永远不变”的状态，一起放进滤波：

$$z = \begin{bmatrix} x \\ a \end{bmatrix} \in \mathbb{R}^2, \quad f(z) = \begin{bmatrix} a x \\ a \end{bmatrix}$$

过程噪声： $Q = \text{diag}(1, 0)$ ——只有 x 有扰动（ a 不动）。

4. 为什么用 EKF（而不是 KF / UKF / PF）？

- f 和 h 都非线性 → KF 不行（KF 只能处理线性）。
- 1D 问题，Jacobian 简单（ $F = \begin{bmatrix} a & x \\ 0 & 1 \end{bmatrix}$ ， $H = [x/\sqrt{x^2 + 1}, 0]$ ）→ EKF 够用。
- 维度低，UKF 的优势（无 Jacobian、2 阶精度）体现不明显。
- 后验双模 PF 更合适，但本题刻意用 EKF 来暴露“双模失败”这一经典坑。

5. EKF 递推细节

初值： $\mu_0 = [1, -1]^\top$ ， $\Sigma_0 = \text{diag}(2, 10)$ 。（ $\mu_a = -1$ 是**关键先验**，让滤波器落在正确模）。

预测： $\mu^- = f(\mu)$ ， $\Sigma^- = F \Sigma F^\top + Q$ 。

更新： $K = \Sigma^- H^\top (H \Sigma^- H^\top + R)^{-1}$ ， $\mu = \mu^- + K(y - h(\mu^-))$ ， $\Sigma = (I - KH) \Sigma^-$ 。

关键观察： H 的第 2 列为 0 → a 不能直接通过 y 更新；信息必须通过 Σ_{xa} 耦合传入。 Σ_{xa} 由 $F = \begin{bmatrix} a & x \\ 0 & 1 \end{bmatrix}$ 在预测步产生。

验证指标

- **最终 $\hat{a}$** ： -1.0008 ± 0.0104 （离真值 < 0.01 → 成功）。
- **σ_a^2 曲线**：单调下降，前期快、后期慢。

- **鲁棒性**：换 $\mu_a = +1$ 初始化 $\rightarrow$ 错误收敛到 $+1$ （双模失败，预期行为）。

1.1 考题（按叙事顺序）

Q1 · 为什么 EKF 能识别 a ? 信息怎么从 y 流到 $\hat{a}$?

一句话: y 通过观测更新 $\hat{x}$; $\hat{x}$ 通过动力学 F 与 $\hat{a}$ 建立协方差耦合 Σ_{xa} ; 下一步更新再把信息灌到 a 。

Q2 · 为什么观测 h 是偶函数就导致双模?

一句话: $h(x) = h(-x) \rightarrow$ 轨迹 $\{x_k\}$ 和 $\{-x_k\}$ 给同样的 y 分布 $\rightarrow a = +1$ 和 $a = -1$ 似然相等 $\rightarrow$ 两个等高峰。

陷阱: 如果换成 $h(x) = x^3$ (奇函数), 就没歧义了。

Q3 · 初始化 $\mu_a = +1$ 会发生什么? 为什么?

一句话: **EKF** 是单模高斯, 被初值推到 $+1$ 附近后会锁死在那一峰, 收敛到错误但自洽的 $+1$ 。

Q4 · Σ_a 为什么只单调下降?

一句话: $Q_{22} = 0$ (a 无过程噪声) + 更新总是收缩协方差 $\rightarrow$ 不会反弹。

Q5 · 为什么前期学得快, 后期学得慢?

一句话: $|h'(x)| = |x|/\sqrt{x^2+1}$ 在 $|x|$ 大时接近 1、 $|x| \rightarrow 0$ 时趋 0; 过程噪声把 x 拖向 0, 后期观测信息量变小。

Q6 · 怎么判断最终估计是否正确?

一句话: 看 $\hat{a}$ 是否在 -1 附近 (< 0.02 量级)、 σ_a 是否收敛到小量、双模初值是否只有“正确初值”能收敛到真值。

2 HW2 P2 · 四元数 UKF 姿态估计

1. IMU 给了什么原始数据？

- **加速度计**: $\text{accel} \in \mathbb{R}^3$, 每帧一个向量, 存储约定是 $[-a_x, -a_y, +a_z]$ (前两轴硬件反向), 带未知 bias.
- **陀螺**: $\text{gyro} \in \mathbb{R}^3$, 每帧一个向量, 存储约定是 $[W_x, W_y, W_z]$, 带未知 bias.
- **时间戳**: ts , 约 100 Hz ($\Delta t \approx 10 \text{ ms}$).

Vicon 提供**真值**: $R \in SO(3)$ 每帧一个旋转矩阵, 用来打分.

2. 这些数据物理意义 — 为什么能描述姿态？

- **加速度计**: 静止时读到的就是重力在 **body frame** 的投影 $q^{-1}gq$. 这告诉你“哪里是向下” → 能反推 **roll** (绕 x) 和 **pitch** (绕 y).
- **陀螺**: 直接测 body-frame 的瞬时角速度 ω . 对时间积分 → 姿态增量 $q_\Delta = \exp(\omega \Delta t / 2)$.
- **二者互补**: 陀螺积分快速但会漂; 加速度计慢但不漂 → 滤波器把它们融合.

关键局限: 加速度计测不到 **yaw** (绕重力轴旋转不改变 g 在 body frame 的投影) → yaw 完全靠陀螺积分 → 长时间会漂.

3. 原始数据有什么问题？标定流程

三个问题:

1. **静态偏置 (bias)**: accel 约 45 m/s^2 , gyro 约 5 rad/s (远大于物理量).
2. **硬件坐标轴**: accel 存储 $[-a_x, -a_y, +a_z]$, 要手动取负.
3. **W_z 标度误差**: 陀螺 Z 轴乘性偏差约 20%, 要乘 $\times 1.20$ 修正.

标定流程: 取前 200 帧 (静止窗口, 已检验 $\text{std} \approx 0$) → accel 均值该是 $[0, 0, 9.81]$ 、 gyro 均值该是 $[0, 0, 0]$ → 差值就是 bias → $\beta = \text{target} - \text{mean}$.

W_z 怎么定: 把陀螺积分的 yaw 和 Vicon 差分的 yaw 比一下, Z 轴总是欠了 20% → 乘 1.20 修正.

4. 姿态用什么数学对象表示？为什么最终选四元数？

三个候选:

表示	维度/约束	问题
欧拉角	3 参数, 无约束	万向节锁 (pitch = $\pm 90^\circ$ 奇异)
旋转矩阵	9 参数, 6 约束	冗余严重, 不易插值/积分
四元数	4 参数, 1 约束 ($\ q\ = 1$)	双覆盖 (q 与 $-q$ 同一旋转), 需要处理

为什么选四元数: 无奇异、参数少、复合便宜 (Hamilton 乘法)、插值/积分自然.

5. 四元数在 S^3 上 — 协方差该怎么放？

核心矛盾: $q \in S^3$ (3 维球面), 不是向量空间 → $q - q'$ 不在 S^3 里 → 协方差没法直接定义.

解法：切空间技巧。在当前均值 $\bar{q}$ 附近用 $\mathbb{R}^3$ （李代数 $\mathfrak{so}(3)$ ）表示扰动：

$$q = \bar{q} \otimes \exp(\delta\theta/2), \quad \delta\theta \in \mathbb{R}^3$$

协方差定义在切空间上 $\rightarrow \Sigma \in \mathbb{R}^{6 \times 6}$ （前 3 维是姿态扰动，后 3 维是角速度）。

6. 最终状态和协方差长啥样？

$$x = \begin{bmatrix} q \\ \omega \end{bmatrix} \in S^3 \times \mathbb{R}^3 \quad (7 \text{ 维状态向量})$$

$$\Sigma \in \mathbb{R}^{6 \times 6} \quad (6 \text{ 维切空间协方差})$$

初值：

- q_0 从第一帧 accel 反推（roll, pitch, yaw 设 0） $\rightarrow$ 避免单位四元数带来的开头 transient.
- ω_0 直接用第一帧校准后的 gyro.
- $\Sigma_0 = 10^{-2} \cdot I_6$ （小但非零）。

7. 为什么用 UKF 而不是 EKF？

- 观测 $h(q) = q^{-1} \otimes g \otimes q$ 对 q 四次非线性 $\rightarrow$ Jacobian 很难推且精度低.
- UKF 无需 Jacobian，用 $2n$ sigma 点采样，精度到 2 阶矩.
- S^3 上做线性化不自然（流形），sigma 点法可以在切空间扰动 + 流形重建的自然流程下工作.

8. UKF 在流形上的一次完整迭代

(8.1) 生成 $2n = 12$ sigma 点（在切空间扰动 + 流形重建）：

$$S = \sqrt{\Sigma} \in \mathbb{R}^{6 \times 6}, \quad W_i = \pm \sqrt{n} \cdot S_{:,i}$$

$$q^{(i)} = \bar{q} \otimes \exp(W_i^{[1:3]}/2), \quad \omega^{(i)} = \bar{\omega} + W_i^{[4:6]}$$

(8.2) 过程模型（每个 sigma 点向前传）：

$$q_{\text{new}}^{(i)} = q^{(i)} \otimes \exp(\omega^{(i)} \Delta t/2), \quad \omega_{\text{new}}^{(i)} = \omega^{(i)}$$

(8.3) 求预测均值 — ω 直接平均； q 用梯度下降求 Fréchet 均值（Kraft EK Sec 3.4）：

1. 初始化 $\bar{q} \leftarrow q_{\text{prev}}$.
2. 循环： $e_i = \log(q^{(i)} \otimes \bar{q}^{-1})$, $\bar{e} = \frac{1}{N} \sum e_i$, 若 $\|\bar{e}\| < \epsilon$ 停；否则 $\bar{q} \leftarrow \exp(\bar{e}/2) \otimes \bar{q}$.
3. 最终 $\{e_i\}$ 就是 sigma 点在切空间的坐标，用来算协方差 $\Sigma^- = \frac{1}{2n} W' W'^T$, $W' = [e_i; \omega^{(i)} - \bar{\omega}]$.

(8.4) 测量模型（对每个新 sigma 点）：

$$\hat{\mathbf{a}}^{(i)} = q^{(i)-1} \otimes g \otimes q^{(i)}, \quad \hat{\omega}^{(i)} = \omega^{(i)}$$

累成 $Z^{(i)} = [\hat{\mathbf{a}}^{(i)}; \hat{\omega}^{(i)}] \in \mathbb{R}^6$.

(8.5) 更新（切空间里线性更新）：

$$K = \Sigma_{xy} \Sigma_{yy}^{-1}, \quad \delta = K(z_{\text{meas}} - \bar{z})$$

$$q_{k|k} = \exp(\delta_{[1:3]}/2) \otimes \bar{q}, \quad \omega_{k|k} = \bar{\omega} + \delta_{[4:6]}$$

$$\Sigma_{k|k} = \Sigma^- - K \Sigma_{yy} K^T$$

9. 噪声参数的设计哲学

- $R_{\text{proc}} = \text{diag}(10^{-4} \cdot I_3, 10^{-2} \cdot I_3)$: 相信陀螺积分 (姿态过程噪声小)、允许 ω 漂 (大)。
- $Q_{\text{meas}} = \text{diag}(200 \cdot I_3, 10^{-3} \cdot I_3)$: **加速度计噪声极大** —— 因为飞行中 $\mathbf{a} \neq$ 纯重力 (含动态加速度), 大噪声让滤波器 “不信” accel 的姿态修正。

验证指标

- **提取 Euler 角**: $q_{\text{est}}.\text{euler_angles}()$ 得 (ϕ, θ, ψ) 。
- **对比 Vicon**: 差分 Vicon 的 R 也提取相同 Euler 角。
- **RMSE 阈值**: 三个数据集都要低于给定的 roll/pitch/yaw 阈值。
- **本题成绩**: 所有 RMSE 低于阈值 (yaw 最接近阈值 0.332/0.35 $\rightarrow$ 正因 yaw 不可直接观测)。

2.1 考题 (按叙事顺序)

Q1 · IMU 给你什么数据? 物理含义是啥?

一句话: accel (带 bias 的 body-frame 力读数, 静止时 = 重力投影) + gyro (body-frame 角速度) + 时间戳。融合可得姿态。

Q2 · 为什么加速度计能告诉你姿态? 局限是什么?

一句话: 静止时 $\mathbf{a} = q^{-1}gq$, 给出 roll/pitch; 但 yaw (绕重力轴旋转) 不改变 g 投影 $\rightarrow$ yaw 无法从 accel 获取。

Q3 · 原始 IMU 数据为什么要标定? 怎么做?

一句话: 有偏置和坐标轴约定 $\rightarrow$ 取 200 帧静止窗口, $\beta = \text{target} - \text{mean}$; 再修 $W_z \times 1.20$ 。

Q4 · W_z 乘 1.20 的依据是什么? 怎么发现的?

一句话: 陀螺 Z 轴是乘性偏差; 把 IMU 的 yaw 积分和 Vicon 差分的 yaw 对比, 发现总欠 20% $\rightarrow$ 乘 1.20。

Q5 · 为什么姿态要用四元数而不是欧拉角或旋转矩阵?

一句话: 欧拉角有万向节锁; 旋转矩阵冗余; 四元数 4 参数 1 约束, 无奇异且复合便宜。

Q6 · 为什么协方差不能直接定义在 S^3 上?

一句话: S^3 不是向量空间, $q - q'$ 不在 S^3 里 $\rightarrow$ 不能定义。解法: 在切空间 $\mathbb{R}^3$ 上放协方差。

Q7 · 最终状态和协方差的维度是什么? 为什么不一样?

一句话: 状态 7 维 (q 4 + ω 3); 协方差 6 维 (q 的扰动只有 3 个自由度, 因为单位约束消掉 1 维)。

Q8 · 为什么用 UKF 而不是 EKF?

一句话: 观测 $q^{-1}gq$ 四次非线性 $\rightarrow$ EKF 的 Jacobian 难推且精度低; UKF 用 sigma 点、无 Jacobian、精度 2 阶, 且天然适配流形扰动。

Q9 · 四元数均值为什么要用梯度下降？不能直接平均吗？

一句话：算术平均会掉出 S^3 （范数 $\neq 1$ ）且不是 Fréchet 均值 $\rightarrow$ 用梯度下降在切空间迭代求真均值。

Q10 · 推导 $q_\Delta = \exp(\omega\Delta t/2)$

一句话：从 $\dot{q} = \frac{1}{2}q \otimes [0, \omega]$ 积分，假设 ω 恒定，指数映射 $\exp(v) = [\cos \|v\|, \sin \|v\|\hat{v}]$ 代入 $v = \omega\Delta t/2$ 。

Q11 · Double cover 是什么？代码里怎么处理？漏了会怎样？

一句话： q 与 $-q$ 同一旋转；若 $q_0 < 0$ ，axis_angle 返回 $> \pi$ 的角 $\rightarrow$ 梯度下降发散。修：safe_axis_angle 里先取正号。

Q12 · 为什么 $Q_{\text{meas}, \text{accel}}$ 设成 200（超大）？

一句话：飞行时 accel 含动态加速度，非纯重力 $\rightarrow$ 模型失配 $\rightarrow$ 大噪声把 Kalman gain 压小，防止 filter 被污染。

Q13 · 初值为什么不用单位四元数？

一句话：机器人开始不一定水平；用第一帧 accel 反推 roll/pitch 作初值，避免大 transient。

Q14 · 如何验证 UKF 估计对不对？

一句话：提取 Euler 角，对比 Vicon GT，计算三个数据集的 roll/pitch/yaw RMSE 是否都低于阈值。

Q15 · 为什么三个数据集的 yaw RMSE 总比 roll/pitch 大？

一句话：yaw 不能由加速度计直接观测 $\rightarrow$ 只靠陀螺积分 $\rightarrow$ 长时间累积 drift。

3 HW3 P1 • Policy Iteration

1. 环境给了什么?

一个 10×10 网格世界:

- **状态**: 100 个格子; 起点 $(1,1)$, 终点 $(8,1)$, 边界 + $(3,2)$ 是障碍.
- **动作**: $\{N, S, E, W\}$, 共 4 个.
- **随机转移**: 0.7 走到意图方向、0.1 左、0.1 右、0.1 原地.
- **奖励**: 终点 0 (吸收)、障碍 -10 (吸收)、其他格子 -1 每步.
- **折扣**: $\gamma = 0.9$.

2. 目标是什么?

找**最优策略** $\pi^*: \mathcal{X} \rightarrow \mathcal{U}$, 使从任意状态出发的**期望累积折扣奖励**最大:

$$J^*(x) = \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_k \mid x_0 = x \right]$$

3. 为什么 MDP 能被 Bellman 方程拆开?

最优性原理: 最优策略的任何子路径仍最优 $\rightarrow$ 价值函数可递归定义:

$$J^*(x) = \max_u \mathbb{E}_{x'} [r(x, u, x') + \gamma J^*(x')]$$

这是 Bellman 最优性方程; **非线性** (含 $\max$), 所以不能直接解。

4. 简化版: 给定 π , 怎么评估它的 J^{π} ?

去掉 $\max$, 就变成线性方程:

$$J^{\pi} = R^{\pi} + \gamma T^{\pi} J^{\pi} \Rightarrow J^{\pi} = (I - \gamma T^{\pi})^{-1} R^{\pi}$$

为什么 $(I - \gamma T^{\pi})$ 可逆: $\gamma < 1$ 且 T^{π} 谱半径 ≤ 1 (随机矩阵) $\rightarrow \gamma T^{\pi}$ 谱半径 $< 1 \rightarrow$ Neumann 级数 $\sum (\gamma T^{\pi})^k$ 收敛.

本题实现: `np.linalg.solve`, $O(n^3) = 10^6$, 毫秒级.

5. 贪婪改进 π'

计算 Q 函数 $Q^{\pi}(x, u) = R(x, u) + \gamma \sum_{x'} T(x, u, x') J^{\pi}(x')$, 然后

$$\pi'(x) = \arg \max_u Q^{\pi}(x, u)$$

Policy Improvement 定理: $J^{\pi'} \geq J^{\pi}$ 逐分量, 等号当且仅当 π 最优.

证明 sketch: $J^{\pi}(x) = Q^{\pi}(x, \pi(x)) \leq \max_u Q^{\pi}(x, u) = Q^{\pi}(x, \pi'(x))$, 递归展开.

6. PI = 评估 + 改进交替

1. 初始化 π_0 (本题用 “always East”).
2. 循环: 评估得 $J^{\pi_k} \rightarrow$ 改进得 $\pi_{k+1} \rightarrow$ 若 $\pi_{k+1} = \pi_k$ 停.

收敛: 策略空间 $|\mathcal{U}|^{|\mathcal{X}|}$ 有限 + 每步严格改进或最优 $\Rightarrow$ **有限步收敛**.

验证指标

- **Policy changes 递减**: $84 \rightarrow 31 \rightarrow 18 \rightarrow 6$ (4 步基本收敛)。
- **起点值单调上升**: $J(1,1)$ 从 -7.54 (East-only) 到 -6.74 (最优)。
- **最终策略几何合理**: 箭头指向目标, 绕过障碍 (3,2)。
- **值函数热图**: 目标周围颜色亮、障碍暗、边界过渡合理。

3.1 考题 (按叙事顺序)

Q1 · 写出 MDP 五元组, 各个分量在本题是什么?

一句话: $(\mathcal{X}, \mathcal{U}, T, r, \gamma)$ — 100 格、4 动作、0.7/0.1/0.1/0.1 转移、奖励 $\{0, -1, -10\}$ 、 $\gamma = 0.9$ 。

Q2 · Bellman 评估方程和最优性方程的区别?

一句话: 评估固定 $\pi \rightarrow$ 线性方程; 最优性含 $\max_u \rightarrow$ 非线性。

Q3 · 证明 $(I - \gamma T^\pi)$ 可逆

一句话: T^π 是随机矩阵谱半径 ≤ 1 ; $\gamma < 1 \rightarrow \gamma T^\pi$ 谱半径 $< 1 \rightarrow (I - \gamma T^\pi)^{-1} = \sum_k (\gamma T^\pi)^k$ 收敛。

Q4 · Policy Improvement 定理怎么证?

一句话: $J^\pi(x) = Q^\pi(x, \pi(x)) \leq \max_u Q^\pi(x, u) = Q^\pi(x, \pi'(x))$, 递归代入得 $J^\pi \leq J^{\pi'}$ 逐分量。

Q5 · 为什么 PI 有限步收敛?

一句话: 策略空间有限 $|\mathcal{U}|^{|\mathcal{X}|}$ + 每步严格改进或最优 $\Rightarrow$ 不超过那么多步就停。

Q6 · PI vs VI 怎么选?

一句话: 小 n 用 PI (精确解 + 几轮收敛); 大 n 用 VI (每步便宜但轮数多)。

Q7 · γ 的作用? $\gamma = 1$ 行吗?

一句话: $\gamma < 1$ 保级数收敛、给出隐式 horizon $1/(1-\gamma)$; $\gamma = 1$ 仅当策略能保证到终止状态才可行 (proper policy)。

Q8 · 怎么验证 PI 真的收敛到最优?

一句话: policy changes = 0 (或做一步改进策略不变); 值函数起点值与已知最优一致; 策略几何上看向目标。

4 HW3 P2 • Particle Filter SLAM (KITTI)

1. KITTI 给了什么数据?

- **LiDAR 扫描**: 每帧 $\sim 10^4$ 点, $(x, y, z, \text{intensity})$, body frame (velodyne).
- **Ground truth poses**: 每帧 3×4 矩阵 $(R|t)$, 作为 **odometry** (注意: 这是“粗略 odom”, 不是直接当真值用).
- **Calibration**: $T_r \in \mathbb{R}^{3 \times 4}$ 从 velodyne 到 camera frame.

2. 为什么能做 SLAM?

- **LiDAR**: 提供环境结构 $\rightarrow$ 用来建图 + 定位 (scan 匹配到已建地图就能知道自己在哪).
- **Odometry**: 提供运动先验 (控制信号 u_t), 减小姿态搜索空间.
- 二者互补: odom 防漂、LiDAR 防错 (闭环效应).

3. 状态应该是什么? 为什么是 2D?

KITTI 车在路面上开, y 轴几乎不变 (垂直); x 前进、 z 左右。所以状态降维到 2D:

$$p = [x, z, \theta] \in SE(2), \quad \theta = \text{绕 } y \text{ 轴的 yaw}$$

地图: 2D 占据栅格, 分辨率 0.5 m, 范围 $[-700, 700] \times [-500, 900]$.

4. 为什么用 Particle Filter?

- 后验分布可能多模: 自相似环境下多个位姿都能解释观测.
- 观测模型不可微: 查“整数化”的地图格子.
- PF 不假设分布形式, 天然支持多模 + 不可微.

代价: 粒子数有限 $\rightarrow$ 后验估计有 Monte Carlo 误差.

5. 粒子怎么初始化?

- 先用 1 粒子 (初始 pose) 做一次观测, 建立初始地图.
- 再用 $N = 50$ 个粒子, 都放在初始 pose, 权重 $1/N$.

6. 预测步: 粒子怎么往前走?

控制: 用 GT pose 差分得到 $u_t = \text{smart_minus_2d}(p_t, p_{t-1})$.

每个粒子:

$$p_t^{(i)} = \text{smart_plus_2d}(p_{t-1}^{(i)}, u_t + n_t), \quad n_t \sim \mathcal{N}(0, Q)$$

为什么用 **SE(2)** 乘法而不是向量加: 平移要先乘 $R(\theta_{t-1})$ 才能加到 t_{t-1} 上 (坐标系正确性).

Q 选取: $\text{diag}(10^{-4}, 10^{-4}, 10^{-5})$, 小但非零 (允许粒子探索邻域).

7. 观测步: 怎么更新权重?

Step A: clean LiDAR (intensity > 0.05 、 $-1 < z < 1.5$ 、距离 $< 30\text{m}$).

Step B: 对每个粒子 i :

1. LiDAR $\rightarrow$ camera (用 T_r) $\rightarrow$ world (用粒子 pose 的 R_y).

2. 查每个点投到的地图格子 $\rightarrow \text{obs_logp} = \sum \text{map_binary}[\text{cells}]$.

Step C: log 域权重更新 + log-sum-exp 归一化:

$$\log w_i^{\text{new}} = \log w_i^{\text{old}} + \text{obs_logp}_i, \quad \log w_i \leftarrow \log w_i - \text{LSE}(\log w)$$

Step D: 用最高权重粒子的 LiDAR 投影更新地图 (log-odds):

- 所有 cell $+\log(1/9)$ (free) .
- 占据 cell $+\log 9$ (occupied) .
- 阈值化得二值 map.

8. 何时重采样?

计算 $N_{\text{eff}} = 1 / \sum w_i^2$; 若 $N_{\text{eff}}/N < 0.3 \rightarrow$ 用 **stratified resampling**:

1. $u_i = (i + U(0, 1))/N$.
2. 用 cumsum $\rightarrow$ searchsorted 找 index.
3. 新粒子 $p_{:,i}^{\text{new}} = p_{\text{old}}[:, \text{idx}(i)]$, 权重重置 $1/N$.

为什么 **stratified**: 方差比 multinomial 小 $\rightarrow$ 粒子多样性保留更好.

9. 提取轨迹

每帧用 $\arg \max_i w_i$ 当前最佳粒子当作估计 $\rightarrow$ 把每帧的 best 连成 **best trajectory**.

这正是“毛刺”的直接来源: 不同帧的 best 粒子 ID 不同 $\rightarrow$ 轨迹离散跳.

验证指标

- **轨迹 vs odom**: PF 轨迹应大致沿着 odom 轨迹, 但在“环境信息丰富”时应更准.
- **地图质量**: 墙面连续、无重影 (ghost walls) .
- **N_{eff} 动态**: 大部分时间靠近 N , 偶尔跌到阈值触发 resample.
- **已知问题**: 轨迹有毛刺 (6 原因, 见 Q10), 不影响地图大局但影响 trajectory smoothness.

4.1 考题 (按叙事顺序)

Q1 • KITTI 给你什么数据?

一句话: 每帧 LiDAR 点云 + GT pose (作 odom) + velodyne-camera calibration.

Q2 • 为什么用 2D 状态而不是 3D?

一句话: 车在 x - z 平面开, y 几乎不变 $\rightarrow$ 降维后计算和搜索空间都小.

Q3 • 为什么用 Particle Filter 而不是 EKF-SLAM?

一句话: 后验可能多模 + 观测模型不可微 $\rightarrow$ PF 天然适配.

Q4 • smart_plus_2d 里为什么平移要乘 $R(\theta)$?

一句话: p_2 的平移定义在局部 frame; 要加到 p_1 平移上, 先旋转到世界 frame.

推导: 齐次矩阵 $T_1 T_2$ 展开 $t_1 + R(\theta_1)t_2$.

Q5 · 推导 $N_{\text{eff}} = 1 / \sum w_i^2$

一句话: **Kish 公式**: 加权估计方差 $\propto \sum w^2 \cdot \text{Var}(f)$; 与等权 N_{eff} 个粒子方差 $\propto \text{Var}(f) / N_{\text{eff}}$ 匹配 $\rightarrow N_{\text{eff}} = 1 / \sum w^2$ 。

Q6 · 为什么权重更新要在 log 域?

一句话: 观测似然极小 (几千 cell 的乘积), 概率域直接乘会下溢; log 域变加法 + log-sum-exp 做归一化。

Q7 · Stratified vs multinomial resampling 差别?

一句话: **Stratified** 在 $[0, 1]$ 每段保证采一个 $\rightarrow$ 方差小、粒子多样性好。

Q8 · 为什么用 log-odds 建图?

一句话: 贝叶斯更新变加法 + 数值稳定 (无下溢) + cell 独立假设下易实现。

Q9 · 为什么只用 best particle 更新地图? 是真正的 FastSLAM 吗?

一句话: 本题是简化版; 真 **FastSLAM** 每粒子一张地图 (内存 $\times N$); **best-particle** 版代价小但地图错误难以回溯。

Q10 · 为什么轨迹有毛刺? (重点!)

一句话: 每帧取 $\text{argmax}(w)$ 作为估计; 不同帧 **best 粒子 ID 跳变** $\rightarrow$ 轨迹离散跳。

6 个原因 (从大到小):

1. **argmax 粒子切换**: 不同帧的 best 粒子不同 ID.
2. **观测似然非光滑**: $\sum$ 整数, 多个粒子 tie, argmax 乱跳.
3. **Resampling impoverishment**: 粒子变成 clone, 多样性丢失.
4. **动力学噪声**: 每步注入 $\sim 10^{-2}$ 扰动.
5. **Monte Carlo 误差**: $N = 50$ 粒子稀疏.
6. **地图反馈**: best-particle 建图, 错误反馈到 likelihood.

缓解: (a) 加权平均轨迹 $\bar{p} = \sum w_i p_i$; (b) 用 log-odds 作 likelihood (平滑); (c) 加粒子; (d) 真 FastSLAM.

Q11 · 怎么验证 PF SLAM 效果?

一句话: (a) 轨迹 vs odom vs 真值; (b) 地图清晰度 (墙面连续、无 ghost); (c) N_{eff} 动态; (d) 肉眼检查渲染。

5 HW3 P3 • TinyNeRF

1. 给了什么数据?

- **图片**: 100 张 800×800 的 LEGO 多视角图; 本题 resize 到 100×100 加速训练.
- **相机位姿**: transforms_colmap.json 里每张图的 4×4 camera-to-world 矩阵.
- **相机内参**: camera_angle_x $\rightarrow$ focal length = 138.89 px (resize 后).

2. 目标是什么?

学一个能渲染任意新视角图像的 **3D 场景表示**.

即: 给一个新 pose, 能吐出一张看起来对的图.

3. 3D 用什么表示? 为什么选神经场?

候选:

- Mesh: 离散顶点, 难优化、难表示半透明.
- Voxel grid: 内存 $O(N^3)$ 爆炸.
- Point cloud: 无表面、难渲染.
- **神经场** $F_\theta(\mathbf{x}) \rightarrow (\mathbf{c}, \sigma)$: 连续、参数少、可微 $\rightarrow$ 选这个.

输出含义: $\mathbf{c} \in [0, 1]^3$ 颜色, $\sigma \geq 0$ 体密度 (单位: 1/长度).

4. 从 3D 场怎么渲染成 2D 像素? (体渲染方程)

沿一条射线 $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$, 积分:

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t)\sigma(t)\mathbf{c}(t) dt, \quad T(t) = \exp\left(-\int_{t_n}^t \sigma(s)ds\right)$$

物理含义:

- $\sigma(\mathbf{x})dt$ 是光在 $\mathbf{x}$ 被吸收/散射的概率.
- $T(t)$ 是从起点传到 t 还没被吸收的概率.
- 积分 = 沿射线累积的颜色期望.

5. 怎么离散化 — α -compositing

采样 $\{t_k\}$, 设 $\delta_k = t_{k+1} - t_k$, 段内 σ 常数:

$$\alpha_k = 1 - e^{-\sigma_k \delta_k}, \quad T_k = \prod_{j < k} (1 - \alpha_j), \quad \hat{C} = \sum_k T_k \alpha_k \mathbf{c}_k$$

推导: $\int_{t_k}^{t_{k+1}} T\sigma\mathbf{c} dt = T_k \mathbf{c}_k (1 - e^{-\sigma_k \delta_k}) = T_k \alpha_k \mathbf{c}_k$.

关键性质: $T_k \alpha_k = T_k - T_{k+1}$, $\sum_k T_k \alpha_k = 1 - T_{N+1} \leq 1$.

6. 怎么沿射线采样? (Stratified sampling)

分层采样:

$$t_k = t_n + \frac{k}{N}(t_f - t_n) + \xi_k, \quad \xi_k \sim \mathcal{U}(0, (t_f - t_n)/N)$$

为什么这样：如果每次迭代都用同样的 $\{t_k\}$ ，NN 只需要记住那 N 个离散点；加随机抖动后，NN 被迫学到连续函数。

7. MLP 输入直接用 $\mathbf{x}$ 可以吗？

不行。NN 有 **spectral bias**（偏爱低频函数），直接喂 $\mathbf{x}$ 学不出高频细节（纹理、边缘）。

Positional encoding:

$$\gamma(\mathbf{x}) = (\mathbf{x}, \sin 2^0 \mathbf{x}, \cos 2^0 \mathbf{x}, \dots, \sin 2^{L-1} \mathbf{x}, \cos 2^{L-1} \mathbf{x})$$

$L = 10 \rightarrow$ 输入维度 $3 \cdot (1 + 2 \cdot 10) = 63$ 。

NTK 视角：PE 让 Neural Tangent Kernel 带宽覆盖 2^{L-1} ，能学到这个频率以下的所有细节。

8. 整条训练 pipeline

每次迭代：

1. 随机选一张训练图 + 它的 pose.
2. 对每个像素发射一条射线 (`get_rays`) .
3. 每条射线上 stratified sample $N = 32$ 个点.
4. 每个点过 PE $\rightarrow$ MLP $\rightarrow (\mathbf{c}_k, \sigma_k)$.
5. α -composite 所有点 $\rightarrow$ 一像素的 RGB.
6. 整张图 vs GT 算 MSE，反传优化 θ .

超参：4 层 MLP、hidden 32、1000 iter、Adam lr 5×10^{-3} 、seed 9458.

激活： $\sigma = \text{ReLU}(\cdot)$ （非负）、 $\mathbf{c} = \text{sigmoid}(\cdot)$ （ $[0, 1]$ ）。

验证指标

- **Loss 曲线**：MSE 从 ~ 0.3 降到 ~ 0.02 （图像 $\in [0, 1]$ ）。
- **训练集对比**：GT（上）vs Pred（下）视觉接近，细节略糊。
- **Novel view**：两张训练 pose 之间线性插值，能看到合理过渡（但 pose 距训练远会失真）。

5.1 考题（按叙事顺序）

Q1 · 输入给了什么？

一句话：100 张多视角图 + 每张的 camera-to-world pose + 内参 (focal)。

Q2 · 为什么用神经场而不是 mesh/voxel？

一句话：连续、参数少（几千）、可微；mesh 离散难优化，voxel 内存爆炸。

Q3 · 体渲染方程的物理意义？

一句话： σdt 是光被吸收概率； $T(t)$ 是光存活到 t 的概率；积分 = 沿射线累积颜色期望。

Q4 · 推导 $\alpha_k = 1 - e^{-\sigma_k \delta_k}$

一句话：段内 σ 常数假设下， $\int T \sigma \mathbf{c} dt = T_k \mathbf{c}_k (1 - e^{-\sigma_k \delta_k})$ ，令 α_k 为括号项即得。

Q5 · 证明 $\sum_k T_k \alpha_k \leq 1$

一句话: $T_k \alpha_k = T_k - T_{k+1}$, 裂项 $\sum = T_1 - T_{N+1} = 1 - T_{N+1} \leq 1$ 。剩余是“背景权重”。

Q6 · Positional encoding 为什么必要?

一句话: NN 有 spectral bias (低频偏好); PE 把输入映到高频空间, 才能学到高频细节。

Q7 · Stratified sampling 好在哪?

一句话: 每次迭代采样点稍有不同 $\rightarrow$ NN 被迫学连续函数, 而不是记住离散 N 个点。

Q8 · σ 用 ReLU、 c 用 sigmoid, 互换会怎样?

一句话: σ 必须非负 (物理量), c 必须 $[0, 1]$ (颜色); 互换破坏物理且训练不稳。

Q9 · 怎么验证训练效果?

一句话: (a) Loss 曲线单调下降; (b) 训练集渲染对比 GT 接近; (c) novel view (pose 插值) 视觉合理。

Q10 · 为什么 novel view 用 pose lerp 是错的? 本题为啥还能用?

一句话: 旋转矩阵线性组合不再正交; 但本题插值距离近、图小 $\rightarrow$ 偏差不明显。正解: SLERP。

6 跨章叙事 · 5 题的共同骨架

每题都在回答一个通用问题

给定有噪声的观测 + 物理模型 $\rightarrow$ 估计不可直接观测的状态。
 差别只在：状态空间的形状和 后验分布的假设。

题	原始数据	状态空间	后验假设	验证指标
HW2 P1	$\{y_k\}$	$(x, a) \in \mathbb{R}^2$	单高斯	$\hat{a}$ vs 真值
HW2 P2	accel + gyro	$(q, \omega) \in S^3 \times \mathbb{R}^3$	流形单高斯	Euler RMSE vs Vi-con
HW3 P1	MDP 五元组	离散 100 格	J^*, π^*	policy changes + $J(1,1)$ 值
HW3 P2	LiDAR + odom	$(x, z, \theta) + \text{grid}$	粒子集	轨迹 + 地图清晰度
HW3 P3	图 + pose	$\theta \in \mathbb{R}^{4292}$	MLE(点估计)	MSE + novel view

跨题 Q1 · 5 题里“状态空间”的核心差异？

一句话：从欧氏空间 $\mathbb{R}^2$ (P1) $\rightarrow$ 流形 $S^3 \times \mathbb{R}^3$ (P2) $\rightarrow$ 离散集合 (P1 MDP) $\rightarrow$ 混合连续离散 (P2 SLAM) $\rightarrow$ 神经网络参数空间 (P3)。状态越怪，需要的数学工具越高级。

跨题 Q2 · 每题最容易出错的地方？

一句话：

- HW2 P1: 双模后验 $\rightarrow$ EKF 收敛到错误模.
- HW2 P2: double cover + 协方差非正定 + Q_{accel} 太小.
- HW3 P1: 目标状态 absorbing 处理不当.
- HW3 P2: best-particle 导致的轨迹毛刺 + cell 独立假设.
- HW3 P3: PE 频率过高/过低 + pose lerp + 相机位姿精度不够.

跨题 Q3 · 给一个题，你会怎么改进？

示例答案：

- P1: 把 EKF 改成 Gaussian Sum Filter, 维护 $a = \pm 1$ 两假设, 用边缘似然淘汰错的.
- P2: 动态加速度检测, 自适应调 Q_{accel} .
- P2 SLAM: 用加权平均轨迹 $\bar{p} = \sum w_i p_i$ 代替 argmax, 去掉毛刺.
- P3: Novel view 用 SLERP 而不是 lerp.

“先走一遍 pipeline, 再回答每个环节。”
 祝口试顺利。